

ICE-ENDES

Infraestructura de Conocimiento sobre la Encuesta Demográfica y de Salud Familiar (Perú, INEI)

Poético en la superficie, científico en la estructura.

28 años de encuestas nacionales no forman, por sí solos, una serie longitudinal.

LO QUE EXISTE

- Microdatos anuales en formato propietario (.sav), diccionarios en PDF por módulo y año.
- ~5,000 variables por año, sin catálogo unificado entre cortes.
- Nombres de variable, escalas y universos poblacionales que cambian sin aviso entre ediciones.
- Diseño muestral complejo (conglomerados, estratos, pesos) que se pierde si no se preserva desde el origen.

LO QUE SE NECESITA

- **Trazabilidad** — cada transformación debe poder auditarse hasta su origen.
- **Comparabilidad** — equivalencias explícitas entre años, con su nivel de confianza declarado.
- **Reproducibilidad** — el pipeline debe ser ejecutable por un tercero, no solo legible.
- **Escalabilidad** — la arquitectura debe sostener décadas de datos, no una consulta puntual.

Un pipeline de ocho capas, cada una con un referente externo que la valida.



Lo que existe hoy, en números

2,832

variables catalogadas — 13 categorías, 0 sin clasificar

37 × 19

variables estratégicas × puntos de verificación, 21 años calendario

45

advertencias metodológicas documentadas, 12 críticas

34,018

personas en la base cognitiva v1, 43 variables

19

diccionarios históricos revisados, 1996–2024

La revisión histórica de estos 19 diccionarios no fue trabajo preliminar: fue la condición para poder diseñar una arquitectura que funcione.

Motor analítico: DuckDB ahora, esquema compatible con PostgreSQL desde el día uno

POR QUÉ NO POSTGRES TODAVÍA

El volumen del proyecto (28 años × ~35 módulos × ~5,000 variables/año) y un único analista no justifican el costo operativo de un servidor. DuckDB ofrece SQL completo, es embebido y no requiere infraestructura propia — el equivalente sin servidor al catálogo que otros proyectos de esta escala sí sirven vía Postgres.

POR QUÉ NO ES UNA DECISIÓN PERMANENTE


El esquema de metadatos se diseña *como si* fuera PostgreSQL desde el inicio: mismas tablas, mismos tipos, mismas restricciones de integridad. La migración deja de ser un rediseño y pasa a ser un *pg_dump* conceptual, activada por umbrales explícitos.

REGLA DE MIGRACIÓN

DuckDB → PostgreSQL quedó definido como decisión activada por evento, no por antojo: concurrencia real de usuarios, control de acceso por rol, o crecimiento del catálogo más allá de lo que un analista único puede sostener sin servidor.

El diseño muestral se preserva en el origen, no se reconstruye al final

Una encuesta con conglomerados, estratos y ponderación no admite análisis directo sobre las filas crudas: ignorar el diseño produce errores estándar incorrectos y conclusiones no válidas para la población. La capa de *survey design* ata conglomerado, estrato y peso a cada tabla curada desde su construcción — nunca como un parche posterior al análisis.



Precedente: **IPUMS-DHS** pre-transforma pesos antes de distribuir

Precedente: **nhanesA** encapsula svydesign()

Reproducibilidad como condición de entrada, no como entregable final

CONTROL DE VERSIONES

Todo script vive en Git desde el primer commit. Sin control de versiones no hay forma de responder —de forma verificable— de dónde salió un número, condición mínima para cualquier hallazgo que aspire a publicación.

LINAJE DE DATOS

Cada transformación queda registrada: origen, script, versión, fecha. La tabla de linaje responde una sola pregunta de forma sistemática — ¿de dónde viene este dato? — en vez de reconstruirla caso por caso.

DOCUMENTO VIVO

Código, resultados y narrativa metodológica conviven en un mismo documento Quarto. El estándar emergente en ciencia abierta, frente al PDF o Word que describe un análisis sin poder ejecutarlo.

Excel se conserva —deliberadamente— como capa de comunicación con colaboradores no técnicos. Nunca como fuente de verdad programática: no es consultable por SQL y no versiona con precisión.

La arquitectura no se diseñó en el vacío: se comparó contra infraestructura ya probada a escala.

US NHANES Registro de variables en PostgreSQL, inmutabilidad por ciclo.	DHS IPUMS-DHS Variables armonizadas entre años y países, pesos pre-transformados.	R nhanesA Encapsula svydesign() y controles de calidad por ciclo.	PE CRONICAS Cohorte peruana (UPCH): profundidad clínica en 4 sitios específicos — complementaria, no equivalente.	LAC SABE Precedente regional en cognición y envejecimiento; ICE-ENDES tiene mayor continuidad temporal (1996–2024).
--	--	--	--	--

LO QUE NINGÚN REFERENTE EXTERNO TIENE

Conocimiento del contexto histórico específico de esta encuesta nacional — discontinuidades de diseño muestral, cambios de instrumento entre ediciones, variables que existen solo en ciertos años — documentado en 45 advertencias metodológicas, trazable variable por variable.

Infraestructura, no un análisis puntual.

La entidad central del sistema es la variable — no la persona, el hogar ni el conglomerado.

El objetivo nunca fue responder una hipótesis. Fue construir el sistema que permite responder muchas — de forma trazable, comparable en el tiempo y reproducible por un tercero — siguiendo el mismo patrón arquitectónico que ya sostiene infraestructura equivalente en otros países.

ROL	STACK	ALCANCE TEMPORAL
Diseño e implementación de la infraestructura de datos completa	Python · DuckDB · Parquet · R (survey) · Git · Quarto	28 ediciones anuales de una encuesta nacional de salud